

שיעורים

מרצה: פרופ' טל גולן
כותב: איתי ענבר

שיעור 1

29.10.2025

מבוא

- יהיה פרויקט סיום:
- הצגה עד חצי שעה
- לקראת סוף הסמסטר
- צריך לזהות איזשהו אתגר ניתוח נתונים בתוך המחקר שלי עם אלמנט של הסקה סטטיסטית
- מידע מלא בשקופיות של שיעור 1
- 65% בחינה מסכמת, 30% פרויקט, 5% הגעה.

המודל הלינארי הכללי

- יש דאטה. יש לנו משתנה תלוי שנרצה להסביר, ונניח שהוא ניתן לתיאור של הרבה משתנים בלתי תלויים (מנבאים). אז יש לי k מנבאים
- אכפיל כל מנבא בשיפוע, אז גם k שיפועים
- יש גם רכיב שארים $residual$.
- יש המון סוגי אנליזות סטייל $avova$, כולם מקרים פרטיים של המודל הלינארי הכללי.
- בכל המקרים שנדון בהם, המשתנה התלוי הוא יחיד וסקלרי. מה שישתנה זה המבנים של המשתנים הבלתי תלויים.
- ברגרסיה לינארית פשוטה יש משתנה ב"ת רציף ויחיד, ובמרובה שניים או יותר.
- כשאני עושה מחקר ניסויי, המשתנה התלוי והב"ת מתבקשים, כי מה שאני מבצע עליו מניפולציה הוא יהיה הבלתי תלוי, לעומה מה שאמדוד שהוא תלוי. אבל זה לא תמיד ככה, והתפקידים יכולים להשתנות בקלות. אני יכול לנבא אושר בעזרת GDP אבל גם לנבא GDP בעזרת אושר.
- בקורלציה מדדנו את הקשר הלינארי בין שני משתנים, והכיוון. בריגרסיה, אנחנו עושים שינוי קטן להגדרות ככה שלא רק נמדוד את עוצמת הקשר אלא גם ממש לנבא את המשתנה התלוי מהבלתי תלוי.
- למשל הבלתי תלוי הוא תוחלת חיים, התלוי הוא רמת האושר.
- אם נתאים את קו הטרנד, נקבל מקדם ואיבר חופשי לניבוי של מתשנה אחד עם השני.
- אז תכלס:

$$y_i = intercept + slope \cdot x_i + residual$$

- למקדמים האלה יש יחידות:

- האיבר החופשי: זה היחידות של המשתנה התלוי
- השיפוע: יש מצב מורכב, זה יחידות המשתנה התלוי חלקי הב"ת.
- איך נשערך את המקדמים האלה?
- אחפש למזער פונקציית שגיאה של סכום השגיאות הריבועיות.
- ה $slopes$ המושלם הוא היחס בין השונות המשותפת של x, y חלקי השונות של x .
- מזכיר שקורלציה לינארית r יכולה להיות מוצגת כשונות משותפת של x, y חלקי מכפלת סטיות התקן.
- זה מביא לזה שאפשר גם לתאר את $slopes$ כמכפלת הקורלציה הלינארית בין x, y ליחס בין סטיות התקן. זה נוח כי אם הקורלציה גבוהה מאוד, אז זה פשוט היחס בין סטיות התקן.
- אם אני לוקח משתנה, מחסר את הממוצע ומחלק בסטיית תקן (תקנון z), אז השיפוע שווה רק לקורלציה עכשיו, וה $intercept$ הוא 0. זה מה שקורה רק אם שני המשתנים מתוקנים
- כשיש חוסר ודאות, המודל רגרסיה הולך לממוצע, זה הפריור שלנו, הבחירה השמרנית.
- מזער פונקציית מחיר מסוימת הביאה לערכים מסוימת לקו הרגרסיה. יש הרבה פונקציות מחיר אחרות למזער שביאו לערכים אחרים בשיערוך.
- מדד $goodness of fit$
- המדד נקרא R בריבוע, או $coefficient of determination$.
- עד כמה טוב המודל מסביר את הנתונים?
- הוא שווה ליחס בין השונות של סטיות הניבויים לסטיות של הממוצע מהערכים האמיתיים.
- אפשר לחשוב על המכנה כמודל טיפוש שתמיד מנבא את הממוצע. במונה יש את סכום הסטיות של המודל בפועל. אם הערך שווה לאפס (כי הניבויים מביאים לטעות 0) ואז הטעות היא 1.
- יכול להיות גם מצב שבו הוא יהיה שלילי, אם הניבוי במונה מתפוצץ
- בריגרסיה לינארית פשוטה ומרובה בשימוש OLS , אז הוא גם שווה לז קטן בריבוע בין y ל y מנובא (כובע). במקרה הכי חמור יהיה 0, כי זה עם ols .
- כשאני במצב של הכללה לנתונים חדשים, ואני מאמן על קבוצה אחת ואז בוחן על חלק ששמתי בצד, אז גם עם OLS הוא עדיין יכול להיות שלילי
- הז קטן בריבוע זה אחוז השונות המוסברת. אם הייתי משערך בשיטה אחרת כאמור, לא היה מובטח לי השוויון הזה.
- אם הכפלתי ב2 את הדאטה, אז r קטן לא ייפגע בכלל, אבל R בריבוע יירד. חשוב לזכור שהם אותו דבר רק בתנאים הספציפיים.

ומה קורה כשיש יותר משני משתנים?

- ההחלטה להסתכל על מקדמים ולהסיק דברים תלויה בהאם האם באותה יחידות מידה או לא, כי הם לא ביחידות של הדבר המנובא. הסקאלה לבדה עוזרת אבל זה לא אותו דבר כמו יחידות מידה.
- אז מה עושים? דרך אחת זה לשערך את הנתונים הגולמיים ואז להכפיל ב(סטיות התקן של הציגונים של המנבא הב"ת k) חלקי סטיית התקן של המשתנה התלוי. כעת נטרלתי גם את הסקאלה של המשתנים השונים, וגם נפתרתי מהיחידות. בטאא זה השיפוע המקורי של המנבא k .
- הדבר הזה שקול ללהריץ את האופטימיזציה על המשתנים כשהם כבר מתוקנים.
- מקדמי רגרסיה מנומרים מייצגים את השינוי של המשתנה התלוי בתגובה לשינוי של סטיית תקן אחת במשתנה הבלתי תלוי, בזמן שאני מחזיק את שאר המשתנים הב"ת קבועים.

- במקרה של רגרסיה לינארית פשוטה, השיפוע המנורמל יהיה שווה לקורלציה בין המשתנה הבלתי תלוי והתלוי. אם זה נהיה מרובה, אז זה לא מחזיק מים יותר.

שיעור 2

5.11.2025

איך מחשבים רגרסיה מרובה?

- מערכת משוואות לינארית אחת:

$$y = X\beta + \epsilon$$

- intercept מאפשר לא לחייב לעבור בראשית הצירים
- המקדם המתאים (בטאות) מגיע כי X בנוי עם עמודה של אחדים בעמודה הראשונה כדי שזה יהיה אפקטיבית פשוט intercept
- יש פה גישה שונה מלמידת מכונה: אנחנו לא מאמנים על חלק מהדאטה ואז בודקים על חדש, אלא מאמנים על כל הדאטה ושואלים שאלות על הבטאות.
- צריך לדעת את פתרון המשוואה של OLS לבעיית רגרסיות מרובות

הקשר בין הקורלציה של המנבא לבטא שלו

- אז ראינו שיש מצב שיש קורלציה גדולה בין מנבא למשתנה התלוי, ויכול להיות שעדיין המקדם יהיה נורא קטן. למה זה קורה? ניקח דוגמה
- נגיד שאני מנסה לנבא את תקיפות הכרישים למכירות ארטיקים בחוף.
- אצליח! הבטא תהיה גבוהה מאפס. יש קורלציה
- אבל אם אוסיף עוד מנבא (למשל כמה אנשים היו בחוף) לאותו דאטה, יכול להיות שהבטא תרד.
- אנחנו יכולים לראות שזה בעצם כמו לשאול את שאלת הניבוי של תקיפות כרישים ממכירת ארטיקים אחרי שלוקחים בחשבון את ההגעה לחוף. השקופית הזאת מראה בדיוק את ההוכחה (משפט פריש-וואה-לובל) לזה.

איך אפשר לתפוס יחסים לא לינארים עם רגרסיה לינארית?

- יש לי מודל רגרסיה לינארית, צריך לבדוק:
- שהשאריות מתפלגות בצורה סבירה.
- להסתכל על y כובע residual (מזכיר, בסטטיסטיקה מאמנים על כל הנתונים ואז שואלים ולכן יש גם רזידואל)
- יש לנו הנחה שהשאריות מתפלגות מסביב כמו רעש מעל הניבויים. אם יש צורה ספציפית של דפוס כלשהו והוא לא נתפס, אז זה מראה שיש לנו בעיה עם להתאים את המודל לנתונים.

- בשביל להגמיש את המודל, אפשר לבצע polynomial expansion: להעלות בחזקה ולתפוס קשרים לא לינארים.
- זו כמובן עדיין ריגרסיה לינארית
- ספר טוב: ISLP book ספר ללמידת מכונה שנכתב על ידי סטטיסטיקאים.
- בהסתכלות על הגרף של ה-y כובע של מנבא כלשהו וה-residual, אני מעדיף לראות רעש מוחלט. אם יש שם דפוס, זה אומר שיש בעיה במודל.
- אבל אני עדיין לא יודע להפריד בין זה לבין overfitting, כי באוברפיטינג אני אראה שם רעש.
- אפשר גם להכפיל מנבא אחד בשני ולחפש את המקדם שלו.
- הערה: המודל עצמו הוא לינארי, אבל היחס של הפרדיקטורים לפרדיקציות הוא לא לינארי, פרמטרים לפרדיקציות הוא כן לינארי
- במצב כשמספר המנבאים שווה למספר המקדמים, אז השארית נהיית אפס. זה מצב לא טוב. אחריו, יש אינסוף פתרונות לממ"ל ההומוגני.
- שימוש ב- R^2 הוא מאוד מטעה במודל עם מנבאים מרובים. הוא מתנפח אם אני מעלה את כמות הפרדיקטורים לא משנה מה הנתונים שאני עובד איתם (גם אם הם רנדומליים לחלוטין). זה משקף את זה שאני מקלף את השונות הלא מוסברת בעזרת עוד ועוד מנבאים.
- לכאן המציאו את $adjusted R^2$. עכשיו האומד הזה הוא לא מוטה, לעומת הראשון שהוא נורא מוטב לחיוב.
- באותה סימולציה, עכשיו היחס בין מספר המנבאים ל- $adjusted R^2$ בתוחלת הוא אפס.
- כדי להבין מה הולך, בלמידת מכונה, אולי נקפא את המודל נביא נתונים חדשים ונראה איך הפרדיקציות שלו נראות.

ביצוע Statistical Inference בריגרסיה מרובה

- אני יכול לקחת גרף של $y = 2x + 3$
- לדגום מההתפלגות הזו ולהוסיף רעש נורמלי. אדגום 100, אשערך את הריגרסיה ותתן לי קו
- כעת אחזור על זה המון פעמים, ועכשיו יש לי את התפלגות המקדמים.
- אבל בניסוי יש לי רק קו אחד. אז מה עושים?
- אפשר לעשות בדיקת השערות וחישוב רווחי סמך ביחס למקדמים מסוימים.
- ברווחי בר סמך יאפשרו לתת לי קצת יותר מבדיקת העשרות
- קונטרסטים: להשוות שני מקדמים. האם הבטא הזו שונה מהבטא הזו? למשל ב-fMRI
- השוואה בין המודל ומודל מופחת

שיעור 3

12.11.2025

תזכורת וחזרה קצרה (מצגת 2, שקופית 24)

- דיברנו על המודל הלינארי הכללי GLM ועל רגרסיה מרובה (מנבאים משתנה רציף וכל המשתנים הבלתי תלויים הם גם רציפים)
- המשתנה התלוי וקטור y
- יש design matrix כל שורה היא תצפית, כל עמודה היא מנבא
- יש מקדמים β שאותם נרצה לשערך
- והשאריות שאותם לא נוכל להסביר.
- דיברנו על איך עושים הסקה סטטיסטית ביחס למודל רגרסיה. לא רק ביחס לנתונים שיש לי ביד. אלא על הפרמטר (פרמטר הוא פונקציה של האוכלוסיה, סטטיסטי הוא פונקציה של המדגם)
- כשאני דוגם נתונים במדגם אחד ויש לי מודל רגרסיה, הוא סטטיסטי, הוא פונקציה של המדגם והוא משקף את המגבלה של הנתונים (רק 100 תלמידים למשל). לכן צריך הסקה סטטיסטית בגלל הפער האמיתי.


Statistical inference on linear regression models

Until now, we only discussed the sample.

But the estimated regression coefficients depend on our noisy observations! In other words, trends that hold in the sample do not necessarily hold in general.

True relationship: $y = 2 + 3x$

OLS regression based on 100 samples



ISLP 2nd edition, Figure 3.3

- ראינו איך בנינו מודל רגרסיה בstats models, ואיך אנחנו קוראים את הדוח שיוצא מהתאמת מודל הרגרסיה, בלוגים.
- תזכורת coeff שיוצא בדוח הוא לא מתוקן וצריך לתקן ידנית.
- דרך אחת זה להריץ את זה כבר על מטריצה X שעברה תקנון z גם בשורות וגם בעמודות.
- דרך אחרת זה להפעיל טרנספורמציה אחר כך.

בדיקת השערות

- בהינתן סט משקולות אנחנו יכולים לנסח השערת אפס ולשערך מרווחי בר סמך לקונטרסט הלינארי.
- האם GDP גדול ממשקל תמיכה חברתית? איך עושים את זה?
- שמים 1 במדד הראשון, 1- בשני ו0 בכל השאר.
- צריך לוודא שאנחנו מתקנים או שהמנבאים באותן יחידות
- אנחנו מתייחסים לintercept כעוד מנבא קבוע
- עכשיו אפשר לשאול: האם אחד גדול מהשני באופן מובהק?

- אז נבצע מבחן t. הוא צריך לקבל משקלים של הקונטרסט

השוואת מודל מלא ומופחת

- מודל מופחת הוא אותו מודל עם כל המנבאים (שזה המודל המלא) רק אחרי שסילקתי חלק ממנו.
- עכשיו אשערך גם את המודל המלא וגם את המופחת על אותם נתונים. עכשיו נשאל האם המודל המלא מסביר טוב יותר את הנתונים מהמופחת. הבעיה היא שהמלא מבחינת ביצועים של R^2 יהיה טוב יותר. אז נבדוק האם זה שיפור מובהק או סתם תוצאה של הוספת מנבא.
- השערת האפס אומרת שכל הפרדיקטורים שאני זורק שווים ל0 (ולא אלה שאני משערך, אלא הפרמטרים באוכלוסיה). ההשערה האלטרנטיבית היא שלפחות מאלה שזרקתי שונה לאפס
- עכשיו אני יכול לחשב Residual Sum of Squares פעמיים: אחד למלא ואחד למופחת. מאחר שאנחנו יודעים שיש הפרש מובנה, אז אנחנו צריכים למצוא סטטיסטי שיעזור לי לזהות תפקוד באמת טוב יותר מעבר להטיה הזו. (הRSS של המודל המלא יהיה קטן מזה של המופחת)

Comparing full and reduced models – partial F test

Residual Sum of Squares (RSS) $\sum_i (y_i - \hat{y}_i)^2$

Consider two models:

- The *full* model with p predictors (+ intercept)
- The *reduced* model omits q predictors from the full model.

RSS_{full}
 $RSS_{reduced}$

Null hypothesis testing:

H_0 : The coefficients of all q omitted predictors equal zero

H_A : At least one omitted predictor has a non-zero coefficient

$$F = \frac{(RSS_{reduced} - RSS_{full})/q}{\frac{RSS_{full}}{n - p - 1}}$$

q omitted predictors
 $p+1$ parameters in the full model
The number of observations

Under H_0 , F has an expected value of 1, and it is distributed according to an F-distribution with $(q, n - p - 1)$ degrees of freedom.

- הסטטיסטי F : ההפרש בין המודלים מנורמל בק מספר הפרמטרים שזרקתי, שאר האלה בשקופית למעלה.
- תחת השערת האפס, ל F יש תוחלת של 1, והוא מתפלג התפלגות F שיש לה שני ארגומנטים.
- גם כשהשערת האפס נכונה, אצפה שהRSS של המופחת יהיה גדול יותר. למודל המלא באופן שיטתי ה R^2 היה גדול מאפס כשאין שום קשרים זה מבחן שאני בודק רק את הזנב הימני.
- אקבע מה ה F הקריטי ולשלוף את אותו ערך F שיש התפלגות של 5% מימינו. או לבדוק מה גודל האינגרל מימין ובודק אם הוא קטן מ0.05.
- אני בעצם מנסה לבדוק אם הוא שונה בצורה מובהקת מ1 במבחן הזה.

סוג רביעי של הסקה (prediction intervals)

- אחרי שיש לי מודל שבחרתי לו את המקדמים, אני יכול לקחת דוגמה חדשה ולשאול איפה המשתנה התלוי שלה נופל. זה יכול להיות ניבוי נקודתי (פשוט להכפיל במשקלים את הקלט). ה $interval$ נותן קצת יותר: יש

סיכוי של 95% שהערך האמיתי שלה נופל בתוך הקטע.

- אם מגיעה מדינה חדשה למדד האושר, אני יכול לקבל אומדן נקודתי של מדד האושר הצפוי בעזרת הכפלת המקדמים והאינטרספט. ב-intervals בהסתברות של 95% האושר של המדינה הזו נמצא בטווח הזה. זה הכחול בשקופית

הגישה הפרמטרית לביצוע inference על OLS

$$y = X\beta + \epsilon$$

- הנחות שנצטרך לתת כדי לבצע inference. אנחנו מניחים את המשואה הידועה והרעש נדגם מהתפלגות יחידה
- כאן X הוא קבוע, β הוא וקטור coefficients האמיתיים.
- זו הנחה נורא חזקה שכל הרעש בעולם נדגם מאותה התפלגות ושיש לו אותה שונות
- עבור הניסוי הכי פשוט, שבו אני דוגם נבדקים וכל נבדק זו תצפית, אז זה מודל סביר. המצב מסתבך כשיש קשר בין התצפיות עבור אותו בן אדם או עבור אנשים.
- איפה זה לא יעבוד? נניח שכל תצפית זה trial.
- בהינתן ההנחות האלה אני יכול לשערך את התפלגויות הדגימה של הערכים ששיערכתי בריגרסיה הלינארית (לא במבחן) אז הבטא המשוערך הוא אומדן בלתי מוטה של הבטא האמיתית
- מה ההנחות שה"כ?

What assumptions enable statistical inference from OLS regression models? LINE

Linear relationship: There exists a linear relationship between the predictors and the dependent variable.

Independence: The residuals are independent.


Normality: The residuals of the model are normally distributed.

Equal Variance: The residuals have constant variance at every level of x (homoscedasticity).

All of these 3 assumptions are about the **residuals**. Violation of these assumptions leads to overly optimistic uncertainty estimates; the effect of such violations on the quality of the model's predictions is often minor.

- הנחת החוסר תלות היא שאין קורלציה בין תצפיות שונות.
- מתי זה לא מתקיים: שכל דגימה היא time point אחד בזמן וזה דאטה series.
- יש תלות סטטיסטית בין תצפית אחת לבאה. אז אני יכול למדל את זה עם ביצוע קורלציה בין הסיגנל לאותו סיגנל כשהוא מוזז. דוגמאות לקורלציות בהזזה כזו:

Example: Serially Correlated residuals



ISI P 2nd edition Figure 3.10

- אפשר לבדוק את זה עם מבחן t .
- אפשר לנסות לפתור את זה גם בעזרת סיכום הדאטה לtimepoint אחד.
- מצב נוסף שיש בו תלות: כל תצפית היא בן אדם אבל אנשים מקובצים לקבוצות. ביצעתי ניסוי בבית ספר, ויש את התלמידים של כיתה אחד וכיתה שניה. עכשיו יש קונפאונדים של מי לימד אותם וכו'.
- לכל אחת מההפרות המדוברות יש מודלים עשירים יותר שמתגברים על הפרת ההנחה. חלקם מגיעים מעולם הפסיכולוגיה וחלקם ממודל של כלכלה.
- הנחה נוספת להיכנס אליה: שהטעות בעלת אותה רעש (איזוטרופיות או הומוסקדיסטיות)
 - אנסה לנבא את משקל החיה מהגודל שלה. עם חיות גדולות יהיו לי שגיאות גדולות (משקל של פיל אטעה בעשרות או מאות ק"ג, לעומת עכבר שאטעה בגרמים). אז השונות שונה עבור גדלים שונים של חיות
 - אנסה לנבא תגובה עצבית מטריאלים. כשיש לי ספייק רייט יותר גבוהה השונות עולה, כשהוא יורד השונות יורדת. אז זה עוד משהו שחותר תחת המודל שאומר ששום דבר לא תלוי בסיגנל.
- פתרונות:
 - גרסיה הטרנסקדיטית: שיהיה לי סיגמה בריבוע שונות לתצפיות שונות. אפשר לבצע GLM ECoG, ולא רצית שיש לי את אותה רמת רעש בכל טריאל (למשל 200-400 שניות אחרי הטריל)
 - ליישר את הנתונים ככה שההנחה תתקיים, לפעמים זה עובד. זה יותר קל. למשל להעביר לlog, מה שמגהץ בגלל עניין הפיכת המכפלות לסכום.
 - נורמליות: נורמליות של אפסילון. אנחנו לא מניחים X או Y מתפלג נורמלית, אלא רק שהרעש מתפלג נורמלית.
 - אז הסטייה של כל תצפית מהערך המנובא שלה מתפלג נורמלית וזה מה שאנחנו דורשים.
 - זו לא התפלגות במשותף.
 - פתרונות למה שקורה כשהיא מופרת:
 - הרבה פעמים המבחן יהיה תקף וסבר. הסיבה לזה היא שאם יש לי הרבה מאוד תצפיות אז חוק הגבול המרכזי עוזר לי בחישובים. אני יכול לקחת את המשתנה שלי ולעשות שהוא יהפוך להיות

נורמלי. אם בכל זאת אני סובל מרעש בבירור לא נורמלי אז יש לי כלי אפרמטרי: residual bootstrapping:

-

Non-normality is not a deal breaker

If the residual normality assumption is violated:

- Often, the tests will still be fine (if we have enough observations, the central limit theorem kicks in).
- Some variables can be transformed to become approximately normal.
- If normality is the only problematic assumption, we can use residual bootstrapping:
 1. Estimate a linear regression model based on the observed data without resampling.
 2. In each bootstrap simulation, generate a new data set by adding a residual sampled with replacement from the original residuals to each $(x_i, \hat{y}_i)$ pair.
 3. Using the simulated datasets, estimate the sampling distribution of the statistic of interest.

- אני יכול לייצר דוגמאות אחרות עם בוטסטרפ, כשאני מחליף רק בין הרעשים. עכשיו אני יכול לחשב את הבטא והניבויים וכו', אבל עכשיו יש לי מכונה שמייצרת לי את התפלגות הדגימה של כל סטטיסטי שאבחר.

- הנחה חבויה של OLS: ה-IV הם חסרי רעש
- הרגרסיה הזו מניחה ש- X נמדד ללא שגיאה. זו הנחה שגויה. נניח שיש לי עמודת אפסים. אז זה ייחשב מנבא מונחת. ההנחתה הזו נובעת מהוספת רעש למנבא שמשטיח את קו הטרנד המשוער. אז ארצה להשתמש במודל רגרסיה חכם יותר שגם ממדל את הרעש בפרדיקטורים ולא רק את המשתנה הבלתי תלוי.

אנובה כמקרה מיוחד של המודל הלינארי הכללי

- לראות Quant Psych ביוטיוב הוא מסביר מושלם
- ספר טוב ANOVA and ANCOVA
- נראה רצף של מודלים שהמנבאים הם משתנים קטגוריאליים.
- רשימה שלהם:

Many parametric statistical analyses are special cases of the general linear model

$$data = slope_1 \cdot predictor_1 + slope_2 \cdot predictor_2 + \dots + slope_p \cdot predictor_p + residual$$

statistical test	independent variables	dependent variable
Simple Linear Regression	1 continuous IV	1 continuous DV
Multiple Linear Regression	2+ continuous IVs	
Two independent samples t-test	1 categorical IV with 2 levels	
One-Way ANOVA	1 categorical IV with 3+ levels	
Factorial ANOVA	2+ categorical IVs	
ANCOVA	1+ categorical IVs and 1+ continuous IVs	
Paired t-test	1 categorical IV with 2 levels and a subject random factor	
Repeated measures ANOVA	1+ categorical IV and a subject random factor	

• נשחק עם דוגמה ספציפית ל t test

Toy data: body temperature in male and female adults

Male ~ N(36.7, 0.4)
Female ~ N(36.9, 0.4)

120 observations, 60 per group

```
print(df.head())
```

	sex	temperature
Adi	female	37.022731
Yisrael	male	36.703303
Tair	female	36.768571
Omer	male	36.412470
Galit	female	37.316790

Descriptive statistics:

```
print(df.groupby("sex").describe())
```

	count	mean	std
sex			
female	60.0	36.934178	0.380556
male	60.0	36.753660	0.422520

• השערת האפס אין הבדל בתוחלות בין הגברים לנשים

T-Test review: Independent-Sample

Does body temperature differ for men vs. women?

Null hypothesis:

$$\mu_{\text{diff}}=0$$

Statistic in our sample:

$$t = \frac{(\bar{X}_M - \bar{X}_W) - \mu_{diff}}{S_{(\bar{X}_M - \bar{X}_W)}}$$

$$S_{(\bar{X}_M - \bar{X}_W)} = \sqrt{\frac{s_M^2 + s_W^2}{N}}$$

If N is the same in both groups, and assume equal variances

Null Distribution of t :

t-distribution with $df=N_M+N_W-2$

- מחלק למטה בטעות התקן.
- מניחים במודל הזה ספציפית שיש הומוסקדיסטיות בין גברים לנשים (יש מודל מורכב יותר למקרה שלא אבל נשתמש בזה בתור דוגמה).
- עכשיו נבנה GLM ששקול מתמטית למה שעשינו פה:
- המשתנה התלוי: טמפ'. הבלתי תלוי: מין. אבל איך אקודד את זה?
- שימוש בספריה שנקראת patsy. היא לוקחת נוסחת wilcoxon togers notation ותתרגם את זה למבאים שאוכל להשתמש בהם בGLM. היא מופעלת על ידי stats models.
- צריך לשים את האות C כדי לסמן קטגוריאלי:

Looking into the design matrix

```
import statsmodels.formula.api as smf
model = smf.ols(
    formula="temperature ~ C(sex)",
    data=df
)

print(model.exog)
```

```
[ [1.  0.]
  [1.  1.]
  [1.  0.]
  [1.  1.]
  [1.  0.]
  [1.  1.]
  [1.  0.]
  [1.  1.]
  [1.  0.]
  [1.  1.]
  [1.  0.]
  [1.  1.] ]
```

	Observed temperature	Intercept	T.male
Adi	37.02	1.00	0.00
Yisrael	36.70	1.00	1.00
Tair	36.77	1.00	0.00
Omer	36.41	1.00	1.00
Galit	37.32	1.00	0.00
Baruch	37.04	1.00	1.00
Miriam	36.71	1.00	0.00
Amir	36.82	1.00	1.00
Hadassah	36.97	1.00	0.00
⋮		⋮	⋮
Shai	35.79	1.00	1.00

- הוקטור השני הוא מקודד את המין כ1 ו0.

שיעור 4

19.11.2025

- (נמשיך את המצגת של שיעור 3) בשיעור הקודם התחלנו לדבר על GLM שמתנהג כמו t-test
 - יש עקרונות מארגנים שמאפשרים אחרי זה לא לזכור את כל שאר פרטי האנובות למיניהן
 - ואז יהיה אפשר להרחיב את זה ליותר משני תנאים, מה ש-t-test לא יודע לעשות
 - בנינו design matrix, ואז intercept ועוד וקטור קידוד (1,0) לגבר/אישה
 - עכשיו בטא 0 יקבל את הערכים של נשים, ובטא 1 יקבל את מה שנשאר, של הגברים.
 - הגדרנו מודל עם statsmodels עם מנובא טמפרטורה ומשתנה קטגוריאלי מין.
 - תזכורת: אנחנו יכולים להשתמש במבחן של Partial F or F-statistic, ככה שאם הוא 1 אז אין הבדל ביכולת של מודל מופחת לנבא את מה שהמודל המלא מנבא, ואחרת ככל שהוא גבוה יותר ו p-value קטן יותר, אז יש יותר כוח למודל המלא לעומת המופחת.
- אני כרגע שואל אם יש הבדל בין המקדמים השונים. בכל מטריצת design שאני אבחר, אקבל משמעות שונה למקדמים.
 - המשמעות כאן היא גודל הסטייה מהממוצע הכללי.
 - ברגע שאני משנה את מקדם ב design matrix, אני משנה את המקדמים כולם בפוטנציה.
- אני יכול גם לעשות cell-mean one-hot encoding. כלומר עכשיו וקטור לגבר ווקטור לאישה (אין אינטרספט כללי כי אין צורך). ואז כל מקדם הוא בעצם הממוצע של כל קבוצה.
- אם יש תלות לינארית במודל רגרסיה שלי, אז statsmodel יחזיר לי פתרון עם הגודל הריבועי של המקדמים הכי קטן, אבל זה לא טוב לפתור בעית רגרסיה שיש לה אינסוף פתרונות (כשמדובר בהסקה).
- כשאני מנסה לשערך את המודל הזה, אז statsmodels אומר שהע"ע הקטן ביותר קטנטן.
- מולטי קולינאריות - יכולת לנבא מנבא בצורה לינארית עם מנבאים אחרים.
 - יכולה להיות מושלמת אבל גם חלקית, וגם היא תפריע לי. ככל שיש לי יותר פרדיקטורים שהם יותר דומים, אז האופן שבו אני מחלק את ההסבר בין המקדמים השונים נהיה יותר ויותר תלוי ברעש (אם הם זהים אז הייתי בוחר מה שאני רוצה). אז הם מאוד תלויים בערכי הספציפיים שיש לי בניסוי.
- מדד פורמלי למולטי קולינאריות: מקדם ניפוח שונות. מדובר בשונות המקדמים. ככל שהשונות יותר גדולה ככה הייתי מצפה לקבל מקדמים שהם כמה שפחות יציבים.
- עבור מקדם מסוים בטאן אני בודק כמה אני יכול לנבא את הפרדיקטור הזה מאחרים.
- אכפת לך מהמדד הזה רק אם המקדם הזה הוא מקדם חשוב שאני רוצה להגיד עליו דברים. אז אם הוא גבוה אני בבעיה. אחרת אפשר להתעלם מזה.
- למדל זמן לימוד כמשתנה תלוי רציף.
- אם אני בונה רק words ~ study_time (ואינטרספט), אז אני מחייב קשר לינארי בין המשתנה התלוי לבלתי תלוי.
- אבל! אם אני מתייחס אליו כמשתנה קטגוריאלי words ~ C(study_time).
 - החיים טובים יותר, מוסיף מקדם לכל אפשרות בקטגוריה
 - במקרה של F זה לא משנה את תוצאות המשחק

- יותר קל לפרש משתנים גולמיים לעומת המתקוננים (מה שדיברנו לפני כמה שיעורים)
- אם אני מוכן להניח הומוסקדיסטיות אז התוצאה במבחן t תהיה זהה למבחן t של GLM, אבל אם לא ואם יש יותר משתנים ויש שונות נפרדת לכל קטגוריה.
- נזכיר partial F - אנחנו מאפסים מקדמים של המודל המלא חוץ מאחד, ואז השערת האפס היא שכל המקדמים שהורדנו שווים לאפס. ואז אפשר להציג את כל ניתוחי השונות לסוגי כמקרים פרטיים של המבחן הזה. מה משתנה זה מה הזהות של המודל המלא ומה הזהות של המודל המופחת.
- אפשר בצורה ידנית לעשות השוואה בין המודל המלא והמופחת

אנובה רב גורמית

- כשיש לי שני גורמים או יותר שמשפיעים על המשתנה התלוי.
- יש לי גם הנחיה מעבר לרמות. בדוגמת זמן הלמידה:
- תלמדו בעל פה
- תחברו סיפור ותדמיינו
- ואז לתאר את המשתנה התלוי כתוצאה של התרומה של הגורמים השונים
- אם אין אינטראקציה כל אחד תורם את התרומה שלו והם נסכמים בצורה אדיטיבית. ברגע שיש לי אינטראקציה, אז ההפרשים בין רמות של גורם אחד הם שונים כשאני עובר לרמה אחרת של הגורם השני.
- אינטראקציה זה שהקומבינציה חשובה. הקומבינציה שלהם בעלת ערך מוסף להסבריות מאשר אם כל אחד מהמשתנים הבלתי תלויים בנפרד.
- נבנה מודל שאין בו אינטראקציה (נתחיל משם)
- $\text{word_count} \sim C(\text{study_time}) + C(\text{instruction})$
- אם אני מבצע anova_lm אני אקבל שני ציוני F: ציון ממודל מופחת אחד שהוריד שני מקדמים (כי הם שייכים לאותו משתנה קטגוריאלי), וציון נוסף רק לאחד מהם.
- ועכשיו נוסיף אינטראקציה:
- $\text{word_count} \sim C(\text{study_time}) * C(\text{instruction})$
- ואז זה יבנה מקדם לכל אחד מהקטגוריות, פלוס כמה בדיוק מקדמים אני צריך.
- עכשיו יהיו לי 3 מבחני F. אחד לראשון, אחד לשני ואחד לאינטראקציה.
- נשאלת השאלה איך בוחנים אפקט עיקרי במודל שיש בו אינטראקציה.
- יש מחלוקת על זה, כל מיני גישות.

שיעור 5

26.11.2025

המשך גורמים עיקריים

- אחרי שבדקנו אינטראקציה, אפשר לבדוק גם את האפקט העיקרי (כל פרדיקטור בעצמו) אחר כך.
- גישה אחת לסיפור: טייפ 3

- אז יש לי $y \sim A:B+A+B$ בלי אינטראקציה. איך נייצר מודל מופחת?
- מודל מופחת יהיה למשל $y \sim A:B+B$
- גישה של טיפ 2:
- אם אין אינטראקציה, אז אין מה להמשיך לאפקט עיקרי.
- אבל אם אני רוצה בכל זאת, אז אני מייצר מודל מופחת גם ללא אינטראקציה
- אז קודם אני מוחק מהמודל "המלא" החדש שאין בו אינטראקציה $y \sim A+B$
- אז לדוגמה זה יוצא $y \sim B$

נדבר על GLM של הרבה תנאים ולא השוואת זוגות

- מערכי ניסוי תוך-נבדקיים
- כל נבדק משתתף בכל התנאים.
- יתרונות:
- יעיל יותר מבחינת זמן וכסף, כי אותו נבדק משתתף בכל התנאים. זה נכון לניסויי מעבדה, אבל בניסויי אונליין זה כבר לא אכפת לי וזה פחות רלוונטי.
- יותר עוצמתי סטטיסטית. כ אם יש לי נבדק מהיר ונבדק איטי, אני יכול לקח תאת זה בחשבון, לנקות את ההבדלים הבין אישיים ואז השונות הבין אישית לא תסתיר לי את השונות של המניפולציה האנושית. אם לכל נבדק יש את ההבדל בין התנאים, אז אני יכול לחסר את ההפרשים ואז זה יהיה נקי משונות בין אישית. אפשר לראות את y כחיבור של השונות הבין אישית פלוס השונות שהניסוי מוסיף.
- חסרונות:
- אפקט העברה (חשיפה לתנאי אחד משפיעה על מה שקורה אחר כך בניסוי) ואפקט סדר. אפקט סדר אפשר לפתור עם רנדומיזציה של הטריאלים. אבל אפקט העברה הוא שונה וקשה לפתור אותו.
- השוואות זוגיות מאפשר לקבל השוואות יעילות (שיש לכל נבדק נקודה בכל תנאי)
- עכשיו נבנה מודל GLM שקול ל $\text{paired } t \text{ test}$ של וקטור ההפרשים
- עכשיו יש לי פרדיקטור קטגוריאלי לכל נבדק שהמספר בו זה הממוצע של כל נבדק (עבור תנאי 0, לראות את שקופית 46 במצגת 3), והאחרון יהיה הוקטור התנאי שאוכל להשתמש בבטא שלו כדי לראות את ההפרש בין התנאים בממוצע. המודל הזה תופס את הכל.
- זה שקול ל $\text{paired } t \text{ test}$.
- דוגמה נוספת בשקופית 50: יהיה לי משתנה בלתי תלוי בדיד, אבל הרמות קורות בכל נבדק. כל נבדק משתתף בכל התנאים.
- מה קורה בין האינטראקציה לנבדק והאינטראקציה הניסויית?
- לסיכום: המודל הזה מוגבל כי הוא נותן לי ציון אחד לכל תנאי, ולכן אני לא יכול להבדיל בין רעש ומניפולציות.
- זה מאפשר לי להתמודד עם מבנה שונות יותר מורכב.
- זה טוב יותר לעומת האנובה שמחייבת שונות איזוטרופית (Between-subjects ANOVA)
- החדש הוא Repeated measures ANOVA, שמאפשר ro שהוא ערך שאכניס בכניסות שונות במטריצת $covariance$.

- ברגע שזה תוך נבדקי יש לי קורלציות בין המדידות של אותו נבדק. אז סז יהיה הערך בכניסות במטריצה של אותו נבדק (זה זהה לכל הנבדקים, זו הנחה שאנחנו לוקחים).
- בדוגמה של טל למטריצה הזו, יש שני נבדקים, אין קורלציה בין הנבדקים (אז יש בלוקים של אפסים), אבל הרו נמצא בתוך כל בלוק. אבל עדיין יש הנחה שהסז כאן הוא אחיד.
- הגדרת sphericity
- הנחה שקשורה להנחת compound symmetry ככל שיש לנו פחות sphericity ככה repeated measures anova יהיה פחות נכון
- איך נמדוד?
- נסתכל על ההפרשים בין תנאים.
- עכשיו אחשב את השונויות של ההפרשים (כל אחד לבד)
- עכשיו אבדוק את ההומוגניות של השונויות. אם הנחת sphericity מתקיימת, אז השונויות הזו צריכה להיות הומוגנית. זה לא אומר שזה שווה, אבל זה אומר שהפרמטר הוא שווה. אז אם זה מתרחק מההומוגניות זה אומר שה repeated measures sphericity, וזה המקום שבו האנובה כבר פחות מתאימה
- בדרך כלל לא יהיה sphericity, וזה המקום שבו האנובה כבר פחות מתאימה
- ההפרה הזו יכולה לקרות רק שיש לי לפחות 3 רמות בתוך גורם.
- ככל שההפרה חמורה יותר ככה גדל הסיכוי לטעות מסוג ראשון
- המדד של אפסילון כובע מודד sphericity. אנחנו רוצים להגיע ל 1 (זה בין 0-1)
- יש מלא דרכים לשערך אותו, אנחנו נשתמש ב greenhouse geisser שהוא שמרני (אנחנו רוצים את זה שמרני כדי שיגן עלינו). אז משערכים אותו ואז משתמשים בו כדי לחשב p-values מתוקנים.
- בהתאם לאפסילון ששיערכתי (למשל עם גרינהאוס גייזר), אשתמש בו כדי לקבוע את התיקון השוואות.
- אפשר גם לעשות בדיקת השערות האם יש בעיה או לא (Mauchly's Test). אבל בכל מקרה היום נהוג לתקן בלי קשר כל עוד יש 3 רמות ומעלה.
- יש ספריה שנקראת pengouin שמאפשרת להשתמש ב Repeated measures anova
- יש גם ANCOVA אני רוצה לכלול מנבא רציף שמסביר חלק מהשונויות. למשל בניסוי של לשון מילים, אולי יש נבדקים שטובים יותר בלדמיין (שונויות בין אישית). אני רוצה להכניס את הפרדיקטור הרציף הזה ואז כל האומדים שלי יהיו מדויקים, וגם המבחן יהיה יותר עוצמתי כי קילפתי עוד שונות שאפשר להסביר
- אז זה משתנה שתורם למשתנה התלוי והוא מסתיר את ההשפעות של הגורמים שמעניינים אותנו. אז צריך לנכות אותו ולכן נכניס אותו כמנבא נוסף.
- אני אמדוד אותו בנפרד, וגם לפני הניסוי, כדי שלא יושפע מהמניפולציה הניסויית (אני גם מניח שאותו פרדיקטור לא מושפע מהמניפולציה הניסויית)
- נהוג למרכז את הפרדיקטור הזה

- מצגת 16!
- נדבר על mixed effects model, דיברנו על repeated measures anova עם תצפיות חוזרות מאותו נבדק שצריך להתמודד איתו
- יש לנו את הcovariate matrix (עם הכמה so שיש שם והוא גם די מוגבל)
- אז עכשיו נראה כלי יותר מודרני שמשתמשים בו יותר ב15 שנים האחרונות. מן הסתם ברגע שיש יותר חופש אז זה נהיה יותר מורכב.
- המודלים האלה מאפשרים מבני תלות בין תצפיות, בין נבדקים שקשורים אחד לשני, אותו גירוי שחוזר על פני נבדקים וכו' וכו'.
- שני מושגים:
- fixed יש לי כמה רמות זהות על פני האוכלוסיה. דוגמה (לקבל טיפול או לא לקבל טיפול)
- random הוא מדגם מהאוכלוסיה. דוגמה: נבדקים.
- נעבור ממודל לינארי כללי לmixed effects

From simple GLMs to mixed models

- Simple model: $y = \mathbf{X}\beta + \varepsilon$.
- Mixed model: $y = \mathbf{X}\beta + \mathbf{Z}u + \varepsilon$.
- β : fixed (population-level) effects. As in simple GLM, we estimate the coefficients to best fit the data.
- u : random (group-level) effects. $u \sim \mathcal{N}(\mathbf{0}, \mathbf{G})$. Its variance-covariance matrix is estimated to best fit the data.
- ε : independent residuals. $\varepsilon \sim \mathcal{N}(\mathbf{0}, \sigma^2 \mathbf{I})$.

4

- ההבדל הוא בין בטא וט. בטא זה סט פרמטרים שאשערך כדי להתאים כמה שיותר טוב לנתונים שאני רואה (זה המודל הכללי הלינארי). u הוא אחר, הוא דגימות מגאוסיאן, הוא יותר דוגמה לאפסילון מאשר לבטא.
- עכשיו הדבר הזה מוכפל במטריצה Z , אז אוכל לתפוס באמצעות Zu ש10 התצפיות הראשונות הגיעו מנבדק אחד, ו10 האחרות מנבדק שני. Z יהיה הdesign matrix ו u יהיה וקטור הרעש. כעת שני הדברים יתנהגו

בצורה שונה שלא יכולתי לתפוס קודם.

- אז u הוא גאוסיאן עם תוחלת אפס וקובריאנס כלשהו שתלוי בהנחות הניסוי והצורה שנבנה את המודל. אבל יהיה לנו בתהליך האמידה כשנשערך את המודל:
- אם במודל הפשוט שיערכנו את הבטא והשונויות של אפסילון, אז עכשיו נשערך את הבטאות, הערכים ש u מקבל, את אפסילון והשונויות של אפסילון
- גם z וגם x הן דיזיין מטריקס. אבל אני לוקח בחשבון שאחד קבוע ואחד מגיע מגאוסיאן. הם הולכים לתאר אפקטים שונים.

Classical repeated measures scenario

- Repeated-measures ANOVA compares conditions within subjects.
- Mixed models generalize this approach: handle missing data, more flexible assumptions.
- Example with random intercept per subject:

$$y_{ij} = \underbrace{\beta_0}_{\text{Baseline (30s)}} + \underbrace{\beta_1[\text{Time}_{ij} = 60s]}_{\text{Effect of 60s}} + \underbrace{\beta_2[\text{Time}_{ij} = 90s]}_{\text{Effect of 90s}} + \underbrace{u_{0j}}_{\text{Subj. Offset}} + \varepsilon_{ij},$$

where $u_{0j} \sim \mathcal{N}(0, \sigma_u^2)$ and $\varepsilon_{ij} \sim \mathcal{N}(0, \sigma_\varepsilon^2)$.

Here:

- i : Index for repeated measures or trials within a subject.
- j : Index for subjects.

7

- ההבדל בין זה לבין repeated anova לא טוב לדוגמה שוטה כמו שקופית 8. אז לדוגמה הזו עדיף היה לעשות repeated measures anova. אם היה לי תצפית חסרה, אז הייתי חייב למחוק את כל הנבדק ב repeated measures וזה לא המצב ב lemma.

Random slopes: the sleepstudy example continued

- Allow subjects to differ in *how* they respond over Days: $(Days|Subject)$.
- Each subject gets their own intercept and slope.

$$RT_{ij} = \underbrace{\beta_0}_{\text{Fixed intercept}} + \underbrace{\beta_1}_{\text{Fixed slope}} Days_{ij} + \underbrace{u_{0j}}_{\text{Random intercept}} + \underbrace{u_{1j}}_{\text{Random slope}} Days_{ij} + \varepsilon_{ij},$$

where $\begin{pmatrix} u_{0j} \\ u_{1j} \end{pmatrix} \sim \mathcal{N}(\mathbf{0}, \Sigma_u)$ and $\varepsilon_{ij} \sim \mathcal{N}(0, \sigma_\varepsilon^2)$.

Here:

- i : Observation index within a subject (e.g., measurement for a specific day).

16

- אז בהנחה שאנחנו רוצים להניח שיש slope לכל נבדק, יש עכשיו
- הקונספט של shrinkage:
- כשאנחנו עושים complete pooling הכי טיפש
- כשאנחנו עושים No Pooling אז יש סלופ אישי fixed. אז כשאנחנו עושים א מודל אוכל לבדוק עבור כל נבדק את הבטא הכי טובה עבורו. הסלופ הכי טוב עבור הנבדק הזה
- ב partial pooling השיפוע הוא מקרי אז הוא מתפלג נורמלית, אז עכשיו השיעור הכי טובים שלנו אולי קצת פחות קיצוניים.
- אז יש פה רגולריזציה או כיווץ לעבר הממוצע הכללי.
- כשאנחנו כותבים (Days/Subject), זה המודל של הרנדום סלופ + אינטרספט, לעומת (Subject/1) שזה רק אינטרספט.
- מה יוצא לי מזה?
- המודל אומר לי יותר על הדאטה. מה התבניות של הרעש? נגיד שבממוצע האפקט יהיה אפס, אבל יש כאלה שמש לא מגיבים וכאלה שממש מגיבים לרעה, אז זה יהיה מובהק!
- אני יכול עכשיו גם להגיד משהו על אוכלוסיית הנבדקים, כי מידלתי את השיפועים של הנבדקים כהתפלגות נורמלית. אז אם אתם שואלים אותי איך יראה סלופ שלהם ושונות.
- עכשיו גם יש לי מודל יותר מדויק, כי אני יכול לקחת דפוסים שיש בדאטה שלא יכולתי לתפוס. זה יכול לתת לי יותר עוצמת ניבוי, אז הרווחים הולכים להצטמצם. אז זה מגן עליי מטעויות סוג ראשון. אז אני מרוויח גם עוצמה וגם בנכונות p-values.

26.11.2025

- תזכורת משיעור קודם, אפשר למדל שני סוגים של אפקטים:
- כשזה אפקט קבוע - זה פרמטרים שמסבירים הכי טוב את הדאטה (כמו הבטא שראינו עד עכשיו)
- לעומת אפקט מקרי - הנחת התפלגות, אנחנו מסתכלים על תצפיות שמתפלגות נורמלית. מסורתית הקלאסי זה הנבדק, אבל יכולים להיות עוד.
- אז בסוף אקבל בטאות כמו מודל לינארי רגיל, גם שונות אפסילון, אבל גם יהיו לי ריאליזציות של u שזה וקטור באורך תצפיות ואפיון של הקובריאנס שלו (למשל אלכסוני, יכול גם משהו מורכב יותר).
- זה כמו חבר של אפסילון, שמאפשר להסביר את מבנה השונות הזו.
- הסיבה היא ששניהם התפלגות נורמלית עם תוחלת אפס ומאפשרים למדל א תהרעש. פשוט בלי הט אני מניח ששי את אותה שונות על לפני התצפיות וחוסר תלות. עכשיו עם Z_u אני יכול לעצב את מבנה התלות בין התצפיות השונות. למשל עבור נבדקים חוזרים זה קלאסי.
- כשאני מוסיף את וקטור u הוא בעצם מתפקד כמו איך שנראה repeated measures anova מבחינת זה שיש וקטור לכל התצפיות מאותו נבדק, אבל הבעיה היא שזה פשוט מספר אחד. לעומת זאת, כאן אנחנו מניחים שהמספר עצמו הוא אפס, עם קובריאנס כזה וכזה.
- במקרה של ההתחלה של מצגת 6, המודל המוצג הוא קטן ופשוט שמסביר, אבל אין לו ממש יתרון על repeated measures ANOVA. היתרון הוא שאם משתמשים ב repeated measures הנבדקים הם fixed effect, ובעצם אפשר לטעון שזה מכליל לנבדקים עצמם אבל לא להתפלגות הנבדקים הכללית.
- יתרון נוסף מהקופסה הוא שזה מאפשר לי להתמודד עם מצב שאין לי את כל התנאים לכל הנבדקים.
- כשאני מוסיף את slopen לכל נבדק תחת תנאי (בנוסף לאינטרספט), אני לא רק מאפשר offset לפי האינטרספט, אלא גם מאפשר להטות את השיפוע בהתאם לנבדק תחת אותו תנאי.
- הקונספט של shrinkage:
- למצוא הסבר חזק על no pooling & partial pooling
- ועכשיו ממשיכים לשיעור חדש:
- אז מה היתרון בשימוש ב random slopes ולא רק אינטרספט
- אנחנו אומרים יותר על הדאטה. אז עכשיו אוכל לדעת אם slopen הביא אותי ללמוד משהו על הנתונים.
- אפשר לחשוב על מניפולציה ניסויית אבל חלק מהנבדקים עולים וחלק יורדים. באנליזה של intercepts בלבד אני אפספס את זה.
- ככל שהמודל יותר נאמן למציאות אז תהיה לנו הסקה סטטיסטית יותר מדויקת, גם לכיוון טעות מסוג אחד וגם לכיוון טעות מסוג 2.
- נחזור ל word count.
- נניח שיש לי בכל נבדק כמו רמות של כל תנאי. בשיטות אנליזה סטנדרטיות היינו ממצעים ועושים אנובה. עכשיו אני יכול להאכיל את המודל בדאטה מורכב יותר שיש לי לכל נבדק הרבה טריאלים ולהגיד משהו על מה שקורה שם.

- ברגע שאני כותב (Time|Subject) אני בעצם משערך slopes לכל נבדק. אני משערך אינטרספט ושתי סטיות מהתפלגות הקוברינס שממנה דוגמים במקביל.
- אני חייב לכתוב את Time בנוסף לנוטציה למעלה כי אז זה יתאים גם בטא כללי לסיפור הזה. אחרת אני מניח שאין הבדל בין התנאים כי התוחלת היא אפס.
- אם יש לי כמה דגימות לכל תנאי בתוך כל נבדק, אני יכול לבצע את השיערוך הזה. אז מעבר למודל חכם יותר, יש פה גם עניין שמבנה הדאטה מאפשר לי לבצע את זה.
- אז בשביל להתאים slopes אני צריך שיהיו לי הרבה תצפיות מאותו תנאי מאותו נבדק.
- נושא נוסף בתוך מודלים לינארים מעורבים: cross random effects
- מודל 1: נתחיל ממודל null שאין בו אפקט לשפה. אז אני אוסיף בנוסף לאינטרספט כללי את הסטיות גם של הנבדקים אבל גם של המילים השונות. הבטא אפס יתפוס את הממוצע של כל זמני התגובה בניסוי והיחיד שאני לא מניח שיש לו תוחלת אפס.
- מודל 2: אותם אפקטים כמו המודל הראשון, אבל גם אינטרספט
- מודל 3: גם random slopes.
- איך אבחר את המודל הנכון?
- אופציה אחת: אבחר את המודל המתכנס הכי מפורט שיש. אם הוא לא מספיק מפורט אז יהיו לי המון טעויות מסוג ראשון.
- השני היא שאנחנו נבחר את המודל המקסימלי ביותר שבמובהק טוב יותר ממודלים פשוטים. אבל יש לי מודל בינוני וגדול והגדול הוא לא טוב במובהק - אז אבחר את הבינוני.

שיעור 8

17.12.2025

- הפעם נדבר על fMRI - תגובת המודל ההמודינמית. מגלם כמה דברים
- רוחב כלי הדם
- זרימת הדם המחומצן
- תגובת הבולד בסדר גודל שמופרד מהפעילות העצבית.
- בשנת 95 קארל פריסטון הציע להשתמש בריגרסיה לינארית כדי למדל את סיגנל הבולד. זה מאפשר להציג גירויים עם חפיפה בתגובות הבולד שלהם ועדיין להיות מסוגל להפריד בין התגובות לכל גירוי.
- כדי לבנות פרדיקטור אפשר לבצע קונבולוציה בין זמני התחלת הצגת הגירוי ל HRF.
- אז בניתי מודל של סיגנל הבולד ביחס לגירויים שלי (בעזרת קונבולוציות)
- עכשיו אני רוצה למדל את הקשר של גירויים שונים בניסוי BOLD.
- נגיד שיש לי תנאי של גירוי פרצופים ועוד אחד של גירויי בתיים.
- אז אייצר בטא אחד של 1ים בשביל לתפוס את המנוחה + בטא לכל תנאי.
- השני ממדל את הפרצופים.
- אז אייצר קונבולוציה בין HRF לבין האורך של הגירויים
- בסוף יהיה לי 3 בטאות לכל ווקסל לכל נבדק
- אז y הוא הסיגנל בולד, ואז הא הראשונים הם regressors of interest ונראים כמו HRF אחרי קונבולוציה עם עליות אחרי כל גירוי. לזה, אני מוסיף עוד פרדיקטורים שמטרתם לתפוס ארטיפקטים (למשל דופק).

- היום fMRI עוקב אחרי הראש שלי הנבדק.
- אם יש לי מולטי קו-לינאריות על הפרדיקטורים של הרעש, זה לא אכפת לי כי אני בודק את אלה שמעניינים אותי.
- כשאני מכניס סט של פרדיקטורים איטיים אז זה כמו לעשות high-pass (אפשר לעשות את שניהם)
- אז עכשיו יש לי אומדן של הבטאות האלה לכל נבדק ובכל ווקסל. בשלב הזה אבצע מבחן t בין כל הבטא 1 ל-0, או בין שני בטאות. עכשיו כל תצפית זה נבדק, אין לי כאן זמן. אז איך זה נראה:
- אז נגיד יש לי 300 דגימות בהקלטה (קצב דגימה של המכשיר)
- אז אני יכול עם אותו GLM לתאר את כל הווקסלים במקביל. B היא מטריצת הבטאות לכל הווקסלים

$$B_{P \times V} = (X_{P \times N}^T X_{N \times P})^{-1} X_{P \times N}^T Y_{N \times V}$$

$$\hat{Y}_{N \times V} = X_{N \times P} B_{P \times V}$$

- אז B משערך את הבטאות, Y_i כובע הוא הניבוי של הפעילות העצבית, של כל המוח עבור נבדק יחיד.
- בשלב השני אני לוקח את הבטאות בתוך כל ווקסל על פני הנבדקים. אוהבים לצייר את הערך t פר ווקסל. אז המצויר זה הווקסל שבו עברו את המובהקות על ידי כל הנבדקים.
- לגבי ההנחות:
- לא הנחנו שווקסל מגיב לגירוי שלנו
- אבל יש לנו הנחות של מודל לינארי שאנחנו רוצים שיתקיימו כדי להשתמש במודל לינארי:
- לינאריות - הנחה לא רעה. בעיקר אם הגירויים מופרדים מספיק אחד מהשני.
- אתגר: אפקט של אדפטציה, אפשרי לתפיסה ופתרון
-
- חוסר תלות - קשרים לינארים בGLM עבור fMRI - זה מופר בענק. סיגנל fMRI הוא איטי. כל תתפית היא נקודת זמן, אז יש תלות חזקה מאוד. פתרון אחד זה גרסאות אחרות של מודלים כלליים שלוקחות תלות בנקודות זמן עוקבות. דרך נוספת זה להלבין החוצה ואז מחשבים את הסטטיסטיקה (פחות טוב). דרך נוספת זה להשתמש בבטאות ששיערכנו. הן לא נהיות מוטות בגלל חוסר התלות (רק השונויות נפגעות), ואת השונויות אבצע בין הנבדקים. זה נקרא two level analysis. עשיתי GLM, יש לי בטא מכל נבדק ועכשיו יש לי סטטיסטיקה ברמת הנבדקים (אני לא יכול להשתמש בטעות התקן של הבטא, אלא רק בבטא עצמה).
- נורמליות
- שונות שווה

שיעור 10

31.12.2025

המשך למידת מכונה

- נמשיך אל KNN - K nearest neighbor
- יש לנו שתי קבוצות, כל נקודה זו דוגמה, עכשיו זה מצייר את גבול המחלקות.

- כשתגיע נקודה חדשה, לבדוק מה המרחק לנקודה הקיימת הקרובה ביותר ומאיזו קבוצה היא. זה 1 nearest neighbor
- זה מאוד רגיש לרעש, אז אנחנו רוצים לעבור ליותר מדוגמה 1, למשל 3-nearest. עכשיו עבור כל דוגמת מבחן אני עושה הצבעה בין שלוש הנקודות הקרובים ביותר.
- כשיש k nearest neighbor זוגי, זה יוצר שטח מפורז ללא החלטה
- אז k הוא היפר פרמטר. בשונה מפרמטר שנלמד מהנתונים, אלא נקבע מראש.
- איך נמצא את k? נסתכל על הtest data, אבל יש בעיה. צריך dev set. זה selection bias
-